

Batch : extraction depuis mariaDB

pour ingestion par
ElasticSearch

| Tâches | Statut | Priorité |
|--|---|---|
| Insérer des données dans MariaDB |  |  |
| Choix de la solution | en cours |  |
| Connexion à Mariadb |  |  |
| Liste des bases de données |  |  |
| Liste des tables dans chaque bdd |  |  |
| Accéder au schéma relationnel | Manuel |  |
| Unifier les tables d'une base en un document | en cours |  |
| Convertir les données récupérer en ndjson | |  |

Problèmes décelés :

Prise en compte des relations présentes dans mariadb

Faire un transfert des tables indépendamment les unes des autres n'est pas suffisant et inutile

Besoin de définir un moyen de synchroniser le batch et le streaming

Pas de colonne de mise à jour donc il faudra que l'on récupère la clé primaire avant la mise en place du streaming

Solutions envisagées :

Extraire chaque table en dataframe, join avec pandas

Pb : la clause pour filtrer la donnée à extraire (nécessite un timestamp ou un champ à valeur unique et croissant) ;

Pour automatiser les pour join avec pandas les champs identiques doivent avoir le même nom

Synchroniser Elasticsearch avec logstash ou Kafka connect

Pb : susceptible de soumettre mariadb à des requêtes bien trop longues

Est ce que les clés primaires sont toujours des timestamp ou des à valeurs croissant ie : il n'y a pas de clé primaires dont les valeurs sont générée aléatoirement

OUI

NON

Est ce que au lancement du streaming il est possible d'accéder à la dernière clé en date

Passage par Logstash ou Kafka Connect

OUI

NON

Spécifier la clé dans la clause WHERE

Lancer le streaming, puis récupérer manuellement la 1ère clé

Connecteurs JDBC



| Problèmes \ Solutions | Script python | Logstash | Kafka Connect |
|--------------------------|---------------------------------|--------------------|--|
| Complexité configuration | + | ++ | +++ |
| Synchronisation | Contraintes sur les clés | ??? | <u>Error</u> |
| Unifier les tables | manuel ou semi-automatisé | Surcharger mariadb | Surcharger mariadb ou Kafka Stream Spark |
| Complexité finale | ++ | ++ | +++ |

